

Er reproduserbarhet nok?

Daraf

15.09.2026

Abstract Et kort sammendrag, en til to avsnitt.

Introduksjon

Denne artikkelen tar for seg begrepet reproduserbarhet i vitenskapelig forskning, og hvorfor det har blitt et sentralt tema de siste tiårene. (McNutt, 2014) påpeker at vitenskap bygger på et fundament av tillit, og at gjenskaping av forsøk er en av de viktigste måtene forskere kan opparbeide seg tillit til egne konklusjoner. Samtidig har flere fagfelt, særlig psykologi, opplevd det som gjerne kalles en «replikasjonskrise» (Ioannidis, 2005); (Simmons et al., 2011), noe som har satt spørsmål ved hvor pålitelig publisert forskning egentlig er.

Artikkelen diskuterer forskjellen mellom reproduserbarhet, replikerbarhet og generaliserbarhet, ser på årsaker til at forskningsresultater ofte ikke lar seg gjenskape, og vurderer om nyere verktøy som Quarto dokumenter kan bidra til å løse noen av disse utfordringene.

Temaet er viktig fordi robust og pålitelig forskning er selve grunnlaget for at vitenskapelig kunnskap kan bygges videre på (**bollen2015?**).

Litteraturgjennomgang

Reproduserbarhet regnes ofte som en nødvendig, men ikke tilstrekkelig, betingelse for replikerbarhet (Jasny et al., 2011). Mens reproduserbarhet handler om å kunne gjenskape resultater med samme data og samme prosedyrer, krever replikerbarhet at man samler inn nye data og likevel finner samme konklusjon [**@bollen2015**]. (Goodman et al., 2016) skiller videre mellom tre typer reproduserbarhet: metodereproduserbarhet, resultatreproduserbarhet og robusthet/generaliserbarhet, og understreker at disse begrepene ofte brukes om hverandre i litteraturen på en måte som skaper forvirring.

En sentral årsak til manglende reproduserbarhet er publiseringsbias. Fordi tidsskrifter i stor grad foretrekker positive og signifikante funn, havner studier uten effekt sjelden i litteraturen - et fenomen (Rosenthal, 1979) omtaler som «the file drawer problem». (Young et al., 2008) argumenterer for at dette kan forstås som en økonomisk logikk: vitenskapelig informasjon behandles som en vare, der signifikante resultater har høyere «markedsverdi» enn nullresultater, noe som forsterker skjevheten i hva som faktisk publiseres. Dette henger tett sammen med problemet med type 1-feil: med et signifikansnivå på 0,05 vil man i gjennomsnitt forkaste en sann nullhypotese i ett av tjue tilfeller, og når kun signifikante funn publiseres, kan store deler av den publiserte litteraturen i verste fall bestå av falske positive funn (Simmons et al.,

2011). (Ioannidis, 2005) går så langt som å hevde at de fleste publiserte forskningsfunn faktisk er falske. Flere store replikasjonsstudier har forsøkt å tallfeste omfanget av problemet.

Open Science Collaboration forsøkte å replikere 100 studier fra tre ledende psykologitidsskrifter, og fant at kun 36 prosent av replikasjonene ga signifikante resultater, mot 97 prosent i de originale studiene (Nosek et al., 2015). Lignende resultater kom frem i Many Labs 2-prosjektet, der bare 54 prosent av 28 replikerte funn viste en statistisk signifikant effekt i samme retning som originalstudien (Klein et al., 2018). Problemet er heller ikke nytt eller begrenset til psykologi: allerede i 1982 forsøkte «The Journal of Money, Credit and Banking»-prosjektet å etterprøve resultater i økonomifaget, og klarte kun å fullt ut replikere 2 av over 70 studier, ofte på grunn av manglende data eller udokumenterte dataprogrammer. Nyere forskning viser at problemet ikke er begrenset til klassiske statistiske metoder. (Kapoor & Narayanan, 2023) peker på at maskinlæringsbasert forskning har sine egne reproduserbarhetsutfordringer, blant annet gjennom det de kaller «data leakage» der informasjon fra testdata utilsiktet lekker inn i treningsdata og gir kunstig gode resultater.

Dette illustrerer at reproduserbarhetsproblemet også følger med når forskningsmetodene endrer seg. På samme måte diskuterer (Freese et al., 2022) hvordan samfunnsvitenskapen de siste årene har tatt i bruk nye praksiser som preregistrering og åpen datadeling for å møte «credibility crisis»-en, men understreker at utviklingen bygger videre på utfordringer som var kjent lenge før begrepet «replikasjonskrise» ble vanlig. Et konkret eksempel på hvor sårbar reproduserbarhet kan være for ytre faktorer, gis av (Schoch, 2024) som viser til at deprekeringen av gratis akademisk API-tilgang hos Twitter/X i 2023 gjorde store mengder tidligere publisert forskning umulig å reproducere i praksis, ettersom datagrunnlaget ikke lenger var tilgjengelig.

Forfatterne foreslår et gradert system for reproduserbarhet, i stedet for en binær reproduserbar/ikke reproduserbar forståelse. Årsakene til manglende replikasjon handler imidlertid ikke bare om metode og tilgjengelighet, men også om insentiver. (Balafoutas et al., 2025) argumenterer for at akademias belønningssystemer, der publisering av nye, positive funn premieres langt sterkere enn replikasjonsstudier som er en vesentlig driver bak krisen på tvers av fagfelt som økonomi, finans og ledelse. Ikke alle er imidlertid enige i hvor stor krisen faktisk er: (Pethick et al., 2025) gjennomgår en britisk parlamentsrapport om temaet og konkluderer med at det per i dag mangler solid empirisk dokumentasjon for hvor omfattende reproduserbarhetsproblemet egentlig er, selv om tiltak likevel foreslås. Som en respons på disse funnene har flere foreslått at selve dokumentet som presenterer forskningen bør inneholde koden som genererer resultatene. Ideen om «literate programming», opprinnelig tilskrevet Knuth, har utviklet seg gjennom verktøy som Sweave og Knitr (Xie, 2014) til det som i dag er R Markdown og Quarto Gentleman & Temple Lang (2007). [Gentleman & Temple Lang (2007)] introduserer begrepet «compendium» en samling av tekst, kode og data som til sammen utgjør et selvstendig, kjørbart dokument som andre kan gjenskape i detalj.

Slike dynamiske dokumenter gjør det mulig å koble tekst og kode direkte sammen, slik at leseren i prinsippet kan kjøre analysen på nytt selv. Likevel er ikke alle enige om at «løsningen» fungerer i praksis. (McCullough et al., 2008) undersøkte dataarkivene til flere økonomitidsskrifter, og konkluderte med at arkivene i liten grad faktisk bidro til at publiserte resultater kunne reproduseres, blant annet fordi mange forfattere aldri leverte inn data. Dette

illustrerer at tekniske løsninger alene ikke er nok, dette kreves også insentiver og kultur for åpenhet (**nosek2015b?**).

Diskusjon

Burde replikerbarhet være et krav for publisering, eller er det å be om for mye?

Argumentet for et krav er at reproduserbarhet er en nødvendig, om enn ikke tilstrekkelig, forutsetning for replikerbarhet (Peng, 2011). Samtidig peker (Pethick et al., 2025) på at vi mangler solid empirisk dokumentasjon for hvor stort problemet egentlig er, noe som gjør det vanskeligere å begrunne strenge krav uten først å forstå omfanget bedre. Full replikasjon, ny datainnsamling og uavhengig etterprøving, som er dessuten ofte kostbart og tidkrevende, og vanskelig å kreve av alle publiserte studier...

Kan Quarto-dokumenter hjelpe med å oppnå reproduserbarhet?

Quarto bygger videre på Sweave, Knitr (Xie, 2014) og R Markdown, og støtter blant annet Zotero/BibTeX for referansehåndtering og eksport til flere formater. Dette gjør metodereproduserbarhet enklere å oppnå, men løser ikke nødvendigvis replikerbarhet eller generaliserbarhet, som avhenger av ny datainnsamling i andre kontekster (Goodman et al., 2016).

Som (Schoch, 2024) viser, kan reproduserbarhet dessuten svekkes av forhold utenfor forfatterens kontroll, som endret datatilgang, det er noe et Quarto-dokument alene ikke kan løse.

Hvilke problem gjenstår, og hvordan kan de løses?

Selv med dynamiske dokumenter gjenstår utfordringer knyttet til pakkeversjoner og programvaremiljø over tid. Bruk av `renv` for å låse pakkeversjoner, og Docker for å sikre identisk kjøremiljø, er foreslåtte løsninger. I tillegg peker (Balafoutas et al., 2025) på at tekniske løsninger må kombineres med endrede insentivstrukturer i academia dersom kulturen for åpenhet skal endres varig, jf. erfaringene fra økonomifagets arkiver (McCullough et al., 2008).

Konklusjon

Reproduserbarhet er en nødvendig, men ikke tilstrekkelig, forutsetning for robust og pålitelig vitenskap (**bollen2015?**). Verktøy som Quarto senker terskelen for metodereproduserbarhet betraktelig, men løser verken publiseringsbias (Young et al., 2008), mangelen på insentiver for å faktisk dele data og kode åpent (McCullough et al., 2008), eller nyere utfordringer knyttet til datatilgjengelighet (Schoch, 2024).

Skal replikasjonskrisen møtes for alvor, kreves trolig en kombinasjon av bedre verktøy, endrede publiseringsnormer og en forskningskultur som verdsetter åpenhet like høyt som nye, positive funn.

Referanser

Balafoutas, L., Celse, J., Karakostas, A., & Umashev, N. (2025). Incentives and the replication crisis in social sciences: A critical review of open science practices. *Journal of Behavioral and Experimental Economics*, 114, 102327. <https://doi.org/10.1016/j.socec.2024.102327>

Freese, J., Rauf, T., & Voelkel, J. G. (2022). Advances in transparency and reproducibility in the social sciences. *Social Science Research*, 107, 102770. <https://doi.org/10.1016/j.ssresearch.2022.102770>

- Gentleman, R., & Temple Lang, D. (2007). Statistical Analyses and Reproducible Research. *Journal of Computational and Graphical Statistics*, 16(1), 1–23.
- Goodman, S. N., Fanelli, D., & Ioannidis, J. P. A. (2016). What Does Research Reproducibility Mean? *Science Translational Medicine*, 8(341), 341ps12–341ps12.
- Ioannidis, J. P. A. (2005). Why Most Published Research Findings Are False. *PLOS Medicine*, 2(8), e124.
- Jasny, B. R., Chin, G., Chong, L., & Vignieri, S. (2011). Again, and Again, and Again. *Science*, 334(6060), 1225–1225.
- Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804. <https://doi.org/10.1016/j.patter.2023.100804>
- Klein, R. A., Vianello, M., Hasselman, F., Adams, B. G., Reginald B. Adams, \relax. Jr., Alper, S., Aveyard, M., Axt, J. R., Babalola, M. T., Bahník, Š., Batra, R., Berkics, M., Bernstein, M. J., Berry, D. R., Bialobrzeska, O., Binan, E. D., Bocian, K., Brandt, M. J., Busching, R., ... Nosek, B. A. (2018). Many Labs 2: Investigating Variation in Replicability across Samples and Settings. *Advances in Methods and Practices in Psychological Science*, 1(4), 443–490.
- McCullough, B. D., McGeary, K. A., & Harrison, T. D. (2008). Do Economics Journal Archives Promote Replicable Research? *Canadian Journal of Economics/Revue Canadienne d'économique*, 41(4), 1406–1420.
- McNutt, M. (2014). Reproducibility. *Science*, 343(6168), 229–229.
- Nosek, B. A., Alter, G., Banks, G. C., Borsboom, D., Bowman, S. D., Breckler, S. J., Buck, S., Chambers, C. D., Chin, G., Christensen, G., Contestabile, M., Dafoe, A., Eich, E., Freese, J., Glennerster, R., Goroff, D., Green, D. P., Hesse, B., Humphreys, M., ... Yarkoni, T. (2015). Promoting an Open Research Culture. *Science*, 348(6242), 1422–1425.
- Peng, R. D. (2011). Reproducible Research in Computational Science. *Science*, 334(6060), 1226–1227. <https://www.ncbi.nlm.nih.gov/pubmed/22144613>
- Pethick, S., Wass, M. N., & Michaelis, M. (2025). Is There a Reproducibility Crisis? On the Need for Evidence-based Approaches. *International Studies in the Philosophy of Science*, 38(4), 287–303. <https://doi.org/10.1080/02698595.2025.2538937>
- Rosenthal, R. (1979). *The File Drawer Problem and Tolerance for Null Results*.
- Schoch, D. (2024). *Computational reproducibility in computational social science*.
- Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant. *Psychological Science*, 22(11), 1359–1366.
- Xie, Y. (2014). Knitr: A Comprehensive Tool for Reproducible Research in R. In V. Stodden, F. Leisch, & R. D. Peng (Eds.), *Implementing Reproducible Computational Research*. Chapman and Hall/CRC.
- Young, N. S., Ioannidis, J. P. A., & Al-Ubaydli, O. (2008). Why Current Publication Practices May Distort Science. *PLoS Medicine*, 5(10), e201.

Appendiks A

Denne rapporten ble utarbeidet i R og Quarto ved bruk av følgende R-pakker: knitr (Xie, 2014) og rmarkdown.

```
R version 4.6.1 (2026-06-24)
Platform: aarch64-apple-darwin23
Running under: macOS Tahoe 26.5.2

Matrix products: default
BLAS:           /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRblas.0.dylib
LAPACK:         /Library/Frameworks/R.framework/Versions/4.6/Resources/lib/libRlapack.dylib; LAPACK version 3.12.1

locale:
[1] en_US.UTF-8/en_US.UTF-8/en_US.UTF-8/C/en_US.UTF-8/en_US.UTF-8

time zone: Europe/Oslo
tzcode source: internal

attached base packages:
[1] stats      graphics  grDevices  utils      datasets  methods   base

loaded via a namespace (and not attached):
[1] compiler_4.6.1    fastmap_1.2.0     cli_3.6.6         tools_4.6.1
[5] htmltools_0.5.9   ote1_0.2.0        rstudioapi_0.19.0 yam1_2.3.12
[9] rmarkdown_2.31    knitr_1.51        jsonlite_2.0.0    xfun_0.60
[13] digest_0.6.39     rlang_1.3.0       evaluate_1.0.5
```

Appendiks B

I arbeidet med denne oppgaven har jeg brukt Chatgpt.com , som støtte i skriveprosessen min for å vudere teksten min om oppgaven jeg har fptt. KI-verktøyet er brukt til:

- Har spurt om teksten min
- Har spurt om mine kilder

Alle forslag fra KI-verktøyet er gjennomgått, tilpasset og kvalitetssikret av meg selv før de ble tatt inn i den endelige teksten.