

Er reproduserbarhet nok?

Author Name

Thursday 10 Sep, 2026

Abstract Et kort sammendrag, en til to avsnitt.

Introduksjon

Denne artikkelen tar for seg begrepet reproduserbarhet i vitenskapelig forskning, og hvorfor det har blitt et sentralt tema de siste tiårene. @mcnutt2014 påpeker at vitenskap bygger på et fundament av tillit, og at gjenskaping av forsøk er en av de viktigste måtene forskere kan opparbeide seg tillit til egne konklusjoner. Samtidig har flere fagfelt, særlig psykologi, opplevd det som gjerne kalles en «replikasjonskrise» [@ioannidis2005; @simmons2011], noe som har satt spørsmål ved hvor pålitelig publisert forskning egentlig er.

Artikkelen diskuterer forskjellen mellom reproduserbarhet, replikerbarhet og generaliserbarhet, ser på årsaker til at forskningsresultater ofte ikke lar seg gjenskape, og vurderer om nyere verktøy som Quarto-dokumenter kan bidra til å løse noen av disse utfordringene. Temaet er viktig fordi robust og pålitelig forskning er selve grunnlaget for at vitenskapelig kunnskap kan bygges videre på [@bollen2015].

Litteraturgjennomgang

Reproduserbarhet regnes ofte som en nødvendig, men ikke tilstrekkelig, betingelse for replikerbarhet [@jasny2011]. Mens reproduserbarhet handler om å kunne gjenskape resultater med samme data og samme prosedyrer, krever replikerbarhet at man samler inn nye data og likevel finner samme konklusjon [@bollen2015]. @goodman2016 skiller videre mellom tre typer reproduserbarhet: metodereproduserbarhet, resultatreproduserbarhet og robusthet/generaliserbarhet, og understreker at disse begrepene ofte brukes om hverandre i litteraturen på en måte som skaper forvirring.

En sentral årsak til manglende reproduserbarhet er publiseringsbias. Fordi tidsskrifter i stor grad foretrekker positive og signifikante funn, havner studier uten effekt sjelden i litteraturen - et fenomen @rosenthal1979 omtaler som «the file drawer problem». @young2008 argumenterer for at dette kan forstås som en økonomisk logikk: vitenskapelig informasjon behandles som en vare, der signifikante resultater har høyere «markedsverdi» enn nullresultater, noe som forsterker skjevheten i hva som faktisk publiseres. Dette henger tett sammen med problemet med type 1-feil: med et signifikansnivå på 0,05 vil man i gjennomsnitt forkaste en sann nullhypotese i ett av tjue tilfeller, og når kun signifikante funn publiseres, kan store deler av den publiserte litteraturen i verste fall bestå av falske positive funn [@simmons2011].

@ioannidis2005 går så langt som å hevde at de fleste publiserte forskningsfunn faktisk er falske. Flere store replikasjonsstudier har forsøkt å tallfeste omfanget av problemet.

Open Science Collaboration forsøkte å replikere 100 studier fra tre ledende psykologitidskrifter, og fant at kun 36 prosent av replikasjonene ga signifikante resultater, mot 97 prosent i de originale studiene [@nosek2015]. Lignende resultater kom frem i Many Labs 2-prosjektet, der bare 54 prosent av 28 replikerte funn viste en statistisk signifikant effekt i samme retning som originalstudien [@klein2018]. Problemet er heller ikke nytt eller begrenset til psykologi: allerede i 1982 forsøkte «The Journal of Money, Credit and Banking»-prosjektet å etterprøve resultater i økonomifaget, og klarte kun å fullt ut replikere 2 av over 70 studier, ofte på grunn av manglende data eller udokumenterte dataprogrammer. Nyere forskning viser at problemet ikke er begrenset til klassiske statistiske metoder. @kapoor2023 peker på at maskinlæringsbasert forskning har sine egne reproduserbarhetsutfordringer, blant annet gjennom det de kaller «data leakage» - der informasjon fra testdata utilsiktet lekker inn i treningsdata og gir kunstig gode resultater.

Dette illustrerer at reproduserbarhetsproblemet også følger med når forskningsmetodene endrer seg. På samme måte diskuterer @freese2023 hvordan samfunnsvitenskapen de siste årene har tatt i bruk nye praksiser som preregistrering og åpen datadeling for å møte «credibility crisis»-en, men understreker at utviklingen bygger videre på utfordringer som var kjent lenge før begrepet «replikasjonskrise» ble vanlig. Et konkret eksempel på hvor sårbar reproduserbarhet kan være for ytre faktorer, gis av @compsocsci2024, som viser til at deprekeringen av gratis akademisk API-tilgang hos Twitter/X i 2023 gjorde store mengder tidligere publisert forskning umulig å reproducere i praksis, ettersom datagrunnlaget ikke lenger var tilgjengelig.

Forfatterne foreslår et gradert system for reproduserbarhet, i stedet for en binær reproduserbar/ikke-reproduserbar-forståelse. Årsakene til manglende replikasjon handler imidlertid ikke bare om metode og tilgjengelighet, men også om insentiver. @incentives2024 argumenterer for at akademias belønningssystemer - der publisering av nye, positive funn premieres langt sterkere enn replikasjonsstudier - er en vesentlig driver bak krisen på tvers av fagfelt som økonomi, finans og ledelse. Ikke alle er imidlertid enige i hvor stor krisen faktisk er: @reprocrisis2025 gjennomgår en britisk parlamentsrapport om temaet og konkluderer med at det per i dag mangler solid empirisk dokumentasjon for hvor omfattende reproduserbarhetsproblemet egentlig er, selv om tiltak likevel foreslås. Som en respons på disse funnene har flere foreslått at selve dokumentet som presenterer forskningen bør inneholde koden som genererer resultatene. Ideen om «literate programming», opprinnelig tilskrevet Knuth, har utviklet seg gjennom verktøy som Sweave og Knitr [@xie2014] til det som i dag er R Markdown og Quarto [@gentlemanlang2007]. @gentlemanlang2007 introduserer begrepet «compendium» - en samling av tekst, kode og data som til sammen utgjør et selvstendig, kjørbart dokument som andre kan gjenskape i detalj.

Slike dynamiske dokumenter gjør det mulig å koble tekst og kode direkte sammen, slik at leseren i prinsippet kan kjøre analysen på nytt selv. Likevel er ikke alle enige om at «løsningen» fungerer i praksis. @mccullough2008 undersøkte dataarkivene til flere økonomitidsskrifter, og konkluderte med at arkivene i liten grad faktisk bidro til at publiserte resultater kunne reproduseres, blant annet fordi mange forfattere aldri leverte inn data. Dette illustrerer at tekniske løsninger alene ikke er nok, dette kreves også insentiver og kultur for åpenhet [@nosek2015b].

Diskusjon

****Burde replikerbarhet være et krav for publisering, eller er det å be om for mye?****

Argumentet for et krav er at reproduserbarhet er en nødvendig, om enn ikke tilstrekkelig, forutsetning for replikerbarhet [peng2011]. Samtidig peker reprocrisis2025 på at vi mangler solid empirisk dokumentasjon for hvor stort problemet egentlig er, noe som gjør det vanskeligere å begrunne strenge krav uten først å forstå omfanget bedre. Full replikasjon - ny datainnsamling og uavhengig etterprøving - er dessuten ofte kostbart og tidkrevende, og vanskelig å kreve av alle publiserte studier...

****Kan Quarto-dokumenter hjelpe med å oppnå reproduserbarhet?****

Quarto bygger videre på Sweave, Knitr [xie2014] og R Markdown, og støtter blant annet Zotero/BibTeX for referansehåndtering og eksport til flere formater. Dette gjør metodereproduserbarhet enklere å oppnå, men løser ikke nødvendigvis replikerbarhet eller generaliserbarhet, som avhenger av ny datainnsamling i andre kontekster [goodman2016].

Som compsocsci2024 viser, kan reproduserbarhet dessuten svekkes av forhold utenfor forfatterens kontroll, som endret datatilgang - noe et Quarto-dokument alene ikke kan løse.

****Hvilke problem gjenstår, og hvordan kan de løses?**

****** Selv med dynamiske dokumenter gjenstår utfordringer knyttet til pakkeversjoner og programvaremiljø over tid. Bruk av `renv` for å låse pakkeversjoner, og Docker for å sikre identisk kjøremiljø, er foreslåtte løsninger. I tillegg peker incentives2024 på at tekniske løsninger må kombineres med endrede insentivstrukturer i academia dersom kulturen for åpenhet skal endres varig, jf. erfaringene fra økonomifagets arkiver [mccullough2008].

Konklusjon

Reproduserbarhet er en nødvendig, men ikke tilstrekkelig, forutsetning for robust og pålitelig vitenskap [bollen2015]. Verktøy som Quarto senker terskelen for metodereproduserbarhet betraktelig, men løser verken publiseringsbias [young2008], mangelen på insentiver for å faktisk dele data og kode åpent [mccullough2008], eller nyere utfordringer knyttet til datatilgjengelighet [compsocsci2024]. Skal replikasjonskrisen møtes for alvor, kreves trolig en kombinasjon av bedre verktøy, endrede publiseringsnormer og en forskningskultur som verdsetter åpenhet like høyt som nye, positive funn.

Referanser

Appendiks A

- Versjon nummer og referanse til R pakken brukt i dokumentet
- R versjon brukt, med referanse

Appendiks B

- Hvordan er KI brukt
- Husk invitasjon til chat